Міністерство освіти і науки України
Національний університет ”Львівська політехніка”
Кафедра систем штучного інтелекту



Звіт до лабораторної роботи №3
З дисципліни
”Інтелектуальний аналіз та візуалізація даних”
на тему:
” Діагностика шкал вимірювання”

Виконала:
Студентка ШІ-32
Ляшко Л.І.
Викладач:
Торська Р.В.

Львів – 2026

Хід роботи

Крок 0: дані та варіант

```
ВАРІАНТ 11   ·   Ляшко Леся   ·   ШІ-32

Ваші вісім стовпців:
   1. Телефон
   2. Примітка
   3. ЛН
   4. Виписка
   5. Ліжко днів
   6. Прокальцитонін
   7. Білок1
   8. Гематокрит2

Ваша пара для аналізу зв’язку: Вік та spO2 без дот
Ваше додаткове питання:
   Стовпець «Вік» можна перетворити на вікові групи «до 40», «40–60», «понад 60». Яка шкала була до перетворення і яка стала? Що ви при цьому втратили і що здобули?
```

Етап 1: Паспорт даних

Телефон

непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23

приклади: ['"0958469788 дружина Ганна"', '"0671778486, 0994887663 дружина Оксана"', '"0958768045, чоловік Степан 0951784726"', '"0959819331. дочка Валентина 0960845205"']

Примітка

непорожніх 45 з 121 | унікальних 44 | типи: str×45

приклади: ['"отримував актемра, часті носові кровотечі, втрата нюху"', '"часта втрата свідомосі в стаціонарі"', '"панкреонекроз"', '"глюкозурія, кетонові тіла в сечі, ЦД, фібриляція передс"']

ЛН

непорожніх 121 з 121 | унікальних 6 | типи: str×121

приклади: ['"III-IV"', '"II-III"', '"II"', '"I"']

Виписка

непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2

приклади: ['datetime.datetime(2022, 3, 10, 0, 0)', 'datetime.datetime(2022, 3, 16, 0, 0)', 'datetime.datetime(2022, 1, 18, 0, 0)', 'datetime.datetime(2022, 1, 13, 0, 0)']

Ліжко днів

непорожніх 120 з 121 | унікальних 40 | типи: int×119, str×1

приклади: ['14', '22', '20', '27']

Прокальцитонін

непорожніх 46 з 121 | унікальних 17 | типи: float×46

приклади: ['np.float64(0.126)', 'np.float64(0.9)', 'np.float64(0.1)', 'np.float64(0.104)']

Білок1

непорожніх 118 з 121 | унікальних 44 | типи: float×118

приклади: ['np.float64(70.0)', 'np.float64(61.8)', 'np.float64(80.5)', 'np.float64(62.6)']

Гематокрит2

непорожніх 101 з 121 | унікальних 34 | типи: float×101

приклади: ['np.float64(45.0)', 'np.float64(57.0)', 'np.float64(37.0)', 'np.float64(34.0)']

Паспорт восьми змінних за шкалами вимірювання

Змінна	**Шкала**	**Обгрунтування**
Телефон	ідентифікатор	ідентифікують спосіб зв’язку з пацієнтом.
Примітка	номінальна	текстовий опис особливостей випадку без природного числового порядку між різними записами.
ЛН	порядкова	Рівні легеневої недостатності мають природний порядок тяжкості, але відстані між сусідніми рівнями не задані.
Виписка	інтервальна	Календарна дата має змістовні різниці в днях, але нуль календаря умовний і відношення дат не має змісту.
Ліжко днів	відношень	Кількість днів перебування має природний нуль, а відношення тривалостей, наприклад 20 до 10 днів, має зміст.
Прокальцитонін	відношень	Концентрація має природний фізичний нуль, тому осмислені і різниці, і відношення між значеннями.
Білок1	відношень	Рівень загального білка є кількісною концентрацією з природним нулем, тому відношення значень має зміст.
Гематокрит2	відношень	Гематокрит є кількісною часткою з природним нулем, тому можна порівнювати відношення значень.

Етап 2

Допустимі статистики

Телефон (ідентифікатор)

{'непорожніх': 120, 'унікальних': 120}

Примітка (номінальна)

{'непорожніх': 45, 'унікальних': 44, 'мода': 'Поліалергетик', 'частота моди': 2}

ЛН (порядкова)

{'непорожніх': 121, 'унікальних': 6, 'мода': 'II-III', 'частота моди': 59, 'медіана': 2.5, 'Q1': 2.0, 'Q3': 2.5}

Виписка (інтервальна)

{'непорожніх': 120, 'унікальних': 90, 'мода': datetime.datetime(2021, 9, 7, 0, 0), 'частота моди': 3, 'середня дата': Timestamp('2022-01-29 18:06:06.101694915'), 'стандартне відхилення, днів': 109.52398452859599}

Ліжко днів (відношень)

{'непорожніх': 120, 'унікальних': 40, 'мода': 10, 'частота моди': 12, 'середнє': 17.883333333333333, 'стандартне відхилення': 12.936940355830204, 'коефіцієнт варіації': 0.7234076620221922}

Прокальцитонін (відношень)

{'непорожніх': 46, 'унікальних': 17, 'мода': np.float64(0.1), 'частота моди': 30, 'середнє': 0.7529565217391306, 'стандартне відхилення': 3.010374682892641, 'коефіцієнт варіації': 3.998072393263121}

Білок1 (відношень)

{'непорожніх': 118, 'унікальних': 44, 'мода': np.float64(70.0), 'частота моди': 12, 'середнє': 66.75338983050847, 'стандартне відхилення': 8.378489778888461, 'коефіцієнт варіації': 0.1255140720218409}

Гематокрит2 (відношень)

{'непорожніх': 101, 'унікальних': 34, 'мода': np.float64(40.0), 'частота моди': 15, 'середнє': 41.14059405940594, 'стандартне відхилення': 7.565992046226612, 'коефіцієнт варіації': 0.18390575584060642}

Етап 3

	Стовпець	Статистика	Значення	Чому безглузде
0	Телефон	середнє кодів категорій	59.500000	Телефон є ідентифікатором: числові коди присвоєні довіль...
1	Примітка	середнє кодів категорій	21.200000	Текстові примітки є номінальними категоріями без порядку...
2	ЛН	середнє умовних рангів	2.285124	ЛН є порядковою шкалою: порядок рівнів відомий, але відс...

Рис 1. Три безглузді числа

Етап 4:

Вік і spO2 без дотації є кількісними змінними шкали відношень. Тому для оцінювання лінійного зв'язку між ними кореляція Пірсона є допустимою.

n = 120, r = -0.1463, p-value = 0.1107

Інтерпретація: слабкий обернений лінійний зв'язок.

Некоректний Пірсона(Вік, умовний код ЛН) = 0.3977, p = 6.287e-06

Це число не слід інтерпретувати як кореляцію з ЛН, бо коди 1–6 задають штучно рівні відстані між порядковими категоріями. Для порядкової змінної доречніше використовувати ранговий підхід, наприклад Спірмена.

Етап 5:

Пілготовка даних

Змінна	**Шкала**	**Підготовка до моделі**
Телефон	Ідентифікатор	Виключити з моделі; контактна інформація
Примітка	Номінальна	Кодувати категорії one-hot за потреби
ЛН	Порядкова	Задати явний порядок категорій
Виписка	Інтервальна (дата)	Перетворити на тривалість від опорної дати
Ліжко днів	Відношень	Очистити до кількості днів; за потреби стандартизувати
Прокальцитонін	Відношень	Очистити числові значення, обробити пропуски
Білок1	Відношень	Очистити та стандартизувати
Гематокрит2	Відношень	Очистити, перевірити пропуски й варіативність

Етап 6:

Виправлення чужого аналізу

№	Помилка аналізу	Правильний підхід
1	Для номінальної змінної «помер/жив» обчислено середнє арифметичне.	Потрібно подати відсоткове співвідношення, до прикалду: 61 пацієнт помер, 60 вижили; це приблизно 50.4% і 49.6%.
2	Різні текстові записи однієї й тієї самої статі помилково трактуються як окремі категорії.	Привести до загального вигляду категорій. Після отримаємо 75 жінок і 46 чоловіків.
3	Порядкову змінну «ступінь КТ» відсортовано лексикографічно.	задати явний порядок легкий < середній < важкий < вкрай важкий < критичний; використовувати частоти, медіану.
4	Стовпець «КТ» може містити діапазон величини, але код бере лише ті значення, які вже є числами.	Перетворити всі записи до єдиного вигляду; для інтервалів узяти, наприклад, середину
5	У «spO2 без дот» змішані відсотки та частки, але середнє обчислено без приведення до одного вигляду.	Значення в інтервалі 0–1 перевести у відсотки множенням на 100.
6	До календарних дат застосовано коефіцієнт варіації, який потребує змістовного природного нуля.	Для дат аналізувати інтервали або розкид у днях від змістовної опорної дати; наприклад, у наборі госпіталізації охоплюють 463 дні.
7	Для двох номінальних змінних застосовано кореляцію Пірсона після довільного кодування статі числами 0/1.	Побудувати таблицю спряженості, виконати χ^2-тест і обчислити V Крамера
8	Мін-макс механічно застосовано до всіх числових стовпців без перевірки шкали та варіативності.	Нормалізувати лише доречні кількісні ознаки та перед цим перевіряти max > min; коди категорій не нормалізувати, сталі ознаки вилучати.
9	Використано df.dropna() для всього набору без аналізу змісту пропусків.	Обробляти пропуски окремо для кожної ознаки, оскільки вони можуть бути змістовними
10	«Дата розтину» використана як дата летальності, хоча вона виникає після смерті пацієнта.	Виключити такі ознаки та оцінювати модель лише на даних, доступних на момент прогнозу; важливість визначати після коректного train/test поділу.

Виправлення помилок в коді:

1) Результат лікування

кількість частка, %

помер/жив

1 61 50.4

2 60 49.6

Середній результат лікування: 1.5

2) Стать після уніфікації

Стать

ж 75

ч 46

У вибірці представлено 4 статі:

Стать

ж 56

ч 34

жін 19

чол 12

3) spO2 без дотації

Неправильне середнє: 82.05

Правильне середнє: 82.79

Етап 7:

Висновки: 1**.** У датасеті результат лікування є номінальною бінарною змінною: 61 пацієнт має значення 1, а 60 — значення 2, тому змістовно порівнювати частоти та частки, а не середнє значення кодів.

2. Після приведення spO2 без дотації до єдиного вигляду середнє становить приблизно 82.79%, а зв'язок між віком і spO2 є слабким оберненим: приблизно -0.271.

3. Перевірка помилкового аналізу показала, що тип pandas сам по собі не визначає допустиму статистику: ознаки, зо приведені не до єдиного вигляду, потребують окремої змістовної перевірки.

Відповідь на індивідуальне запитання:

Стовпець «Вік» можна перетворити на вікові групи «до 40», «40–60», «понад 60». Яка шкала була до перетворення і яка стала? Що ви при цьому втратили і що здобули?

До перетворення «Вік» є кількісною змінною шкали відношень: вік має природний нуль, різниці між значеннями мають зміст, і твердження «60 років удвічі більше за 30 років» математично коректне щодо тривалості життя. Після поділу на групи «до 40», «40–60», «понад 60» змінна стає порядковою категоріальною: категорії мають природний порядок, але відстань між ними вже не визначена. Ми втрачаємо точне значення віку та частину інформації про відмінності всередині груп: наприклад, 41 і 60 років стають однією категорією. Натомість отримуємо простіше представлення, яке легше використовувати для групових порівнянь. 3 пацієнти «до 40», 37 — «40–60» і 81 — «понад 60», тому після групування особливо помітною стає перевага старшої вікової групи